



매핑 데이터 플로우(Mapping Data Flow, MDF)

- 코드 없이 시각적으로 ETL(데이터 추출, 변환, 적재) 변환을 설계할 수 있는 기능
- ADF 내에서 GUI로 구성하고 Spark 엔진으로 실행
- 특징
 - GUI 기반 데이터 변환 설계 (코딩 불필요)
 - 대용량 병렬 처리 (Spark 기반)
 - ADF 파이프라인 내 Activity로 사용 가능
- 활용 예시
 - 원시 데이터 정제
 - 로그 분석 전처리
 - DWH 적재 전 변환
- 주요 구성 요소

구성 요소	설명
Source	데이터 입력 (Blob, SQL 등)
Transformation	데이터 변환 로직 적용
Sink	데이터 저장 (Blob, SQL 등)

- 주요 변환 기능

기능	설명	예시
Select	컬럼 선택 및 이름 변경	필요한 열만 추출
Filter	조건으로 행 필터링	오류 로그만 추출
Join	다른 스트림과 조인	사용자 정보 병합
Aggregate	그룹화 및 집계	과목별 평균 계산
Derived Column	계산 컬럼 생성	평균, 등급 파생
Sort	정렬 수행	성적순 정렬
Pivot	열을 행으로 변환	카테고리 분석

- 흐름 제어 기능

- **Conditional Split**: 조건 분기 (예: 나이별 분류)
- **Exists / Lookup**: 외부 참조 존재 여부 판단

MDF 실행 방식

- 실행 흐름
 - ADF 파이프라인 내 **Data Flow Activity**로 호출
 - *Integration Runtime(IR)**에서 Spark 클러스터 자동 생성/종료
- 디버그 모드
 - Sample 데이터 기반 결과 시각 확인
 - 실시간 컬럼 파생, 오류 점검 가능

실습 예시 흐름

1. 데이터 준비
 - Kaggle: Student Performance in Exams
 - Blob Storage의 **input**, **output** 컨테이너 사용
2. MDF 생성
 - Source 설정 → 파생 컬럼(평균, 등급) → Sink 저장
3. 파이프라인 생성 및 실행
 - MDF를 포함한 파이프라인 구성 및 실행
4. 디버깅 및 결과 확인
 - 실시간 결과 확인 후 배포 가능

[비교] Pipeline vs Mapping Data Flow

항목	Pipeline	MDF
역할	흐름 제어	데이터 변환
실행 방식	Copy/Trigger 등 통합관리	Spark 기반 변환 실행
디버깅	전체 흐름 단위	샘플 데이터 기반