



Exist 변환

✅ Exists 변환 개요

- **Exists 변환이란?**
 - 두 개의 데이터 스트림을 비교하여, 왼쪽 스트림의 각 행이 오른쪽 스트림에 존재하는지를 확인하고 boolean 열로 결과를 추가하는 기능
- **특징 및 장점**
 - Join보다 성능 우수 (단순 존재 여부 판단)
 - 조건 기반 분기 처리에 용이
 - 데이터 정합성 및 품질 향상
- **활용 예시**
 - 기존 고객 DB와 비교하여 신규 고객만 필터링 → `Doesn't Exist`
 - 주문 데이터의 상품 코드가 실제 판매 상품에 존재하는지 확인 → `Exists`
 - 데이터 처리 전 참조 무결성 검증 (ex. 부서 ID 확인)

✅ Surrogate Key 변환 개요

- **Surrogate Key란?**
 - 각 행에 대해 고유하고 순차적으로 증가하는 정수형 키를 생성하는 변환
- **특징 및 장점**
 - 고유성 보장 및 간단한 설정
 - 비즈니스 키 변경에도 영향 없음
 - DW 모델링 시 안정적인 키 제공
- **활용 예시**
 - 고유 식별자가 없는 원본 데이터에 임시 ID 부여
 - 순차적인 기본키를 사전 생성하여 로드용도로 사용
- **설정 요소**
 - 키 열 이름 지정 (예: `CustomerKey`)
 - 시작 값 지정 (기본값: 1)

✅ 실습 1: 신규 레코드 확인 실습

실습 구성도

```
Blob - input (CSV)
└─ ForEach
    └─ Data Flow
        ├── Source1: updated data
        ├── Derived Column1 (해시 생성)
        ├── Source2: original data
        ├── Derived Column2 (해시 생성)
        ├── Exists: 존재 여부 비교
        └─ Sink: 신규 레코드 저장 (employees_new_records.csv)
```

실습 절차 요약

1. 데이터 준비
 - employees_updated.csv (신규)
 - employees_original.csv (기존)
2. 컨테이너 구성
 - input / output 컨테이너 설정
3. SQL DB 테이블 준비
 - employees_target 테이블 생성 및 기존 데이터 로드
4. Data Flow 구성
 - Source1/2 설정 → Derived Column (해시 생성)
 - Exists 변환 설정 (조건: 해시 컬럼)
 - Sink에 결과 저장
5. 파이프라인 구성 및 실행
 - Blob → ForEach → Data Flow 연결 후 실행

✅ 실습 2: 중복 레코드 확인 실습

실습 구성도

```
Blob - input (employees_duplicated.csv)
└─ ForEach
    └─ Data Flow
        └─ Source (중복된 CSV)
```

└─ Derived Column (해시 생성)
└─ Surrogate Key (고유 ID 부여)
└─ Select (중복여부 판단 기준 추출)
└─ Exists (중복 여부 확인)
└─ Sink (중복 레코드 저장)

실습 절차 요약

1. 데이터 준비

- employees_duplicated.csv, employees_duplicated_records.csv

2. Data Flow 구성

- Source 설정 (중복 파일)
- Derived Column으로 해시값 생성