



증분 데이터 로드

✓ 1. 개요: 증분 데이터 로드란?

- **증분 데이터 로드(Incremental Load):** 전체 데이터가 아닌 변경된 데이터만을 추출 및 적재하는 방식
- **목적:** 효율적인 데이터 적재, 실시간 분석, 자원 절약
- **핵심 기술:** CDC (Change Data Capture)
 - 변경 감지: Insert, Update, Delete 이벤트 감지
 - 변경 추출: 트랜잭션 로그, 타임스탬프, 트리거 기반
 - 변경 전파: 변경된 데이터만 대상 시스템에 반영

✓ 2. 실습 기본 구성

- **입력:** Blob - input 컨테이너
- **출력:** Blob - output 컨테이너
- **핵심 파일들:**
 - `orders_initial.csv` : 최초 전체 데이터
 - `orders_incremental.csv` : 증분 데이터 모음
 - `watermark.txt` : 이전 실행 시점 기록 (e.g., `1900-01-01T00:00:00Z`)
 - `incremental_data_*.csv` : 날짜별로 업로드된 증분 파일들

✓ 전체 흐름

1. 이전 실행 시각 조회 (`watermark.txt`)
2. 현재 실행 시각 저장 → `NewWatermarkValue = @utcnow()`
3. 조건 필터링: `watermark < 파일 업로드 시각 < NewWatermarkValue` 만족하는 데이터만 Copy
4. 데이터 복사: 조건 만족하는 증분 파일을 대상(output)에 적재
5. 워터마크 갱신: 현재 시각을 `watermark.txt` 에 저장

✓ 3. 실습 준비

- **Blob 컨테이너 구성**
 - `input` : 증분 및 초기 파일 업로드

- `output` : 적재 결과 저장
- 실습용 파일 준비
 - `orders_initial.csv`
 - `orders_incremental.csv`
 - `orders_incremental_3rd.csv` , `4th.csv` , `5th.csv`
 - `watermark.txt` : `1900-01-01T00:00:00Z` 초기값 설정

✓ 4. 파이프라인 구성

✓ 구성요소

1. **Lookup**: 이전 실행 워터마크 값 조회 (`watermark.txt` 첫 행)
2. **Set Variable**: 현재 시각을 `NewWatermarkValue` 변수에 저장

```
NewWatermarkValue = @utcnow()
```

3. **Filter 조건 적용 후 Copy**: 아래 조건을 만족하는 파일만 적재

```
watermark < 업로드 시각 < NewWatermarkValue
```

4. **Copy Activity**: 조건을 만족하는 증분 CSV 복사
5. 워터마크 파일 갱신: `NewWatermarkValue` 를 다시 `watermark.txt` 로 저장

✓ 5. 게시 및 실행 단계

✓ 초기 실행

- `orders_initial.csv` → output 컨테이너에 적재
- watermark: `1900-01-01T00:00:00Z`

✓ 증분 실행 1

- `orders_incremental.csv` 업로드
- 조건 만족하는 데이터만 복사
- watermark 갱신

✓ 증분 실행 2~3

- 3rd, 4th, 5th 파일 순차 업로드 후 실행
- 각각의 실행에서 watermark 조건에 맞는 데이터만 적재됨

✓ 6. 전체 흐름 요약

```
Blob - input
└─ ForEach
    └─ Pipeline
        ├── Lookup (이전 watermark 확인)
        ├── Set Variable (현재 시간 저장)
        ├── Copy (조건 만족 시 데이터 적재)
        └─ Copy (워터마크 갱신)
Blob - output
```

✓ 7. 마무리 및 활용

- **장점:** 데이터 처리 비용 최소화, 최신 데이터 유지, 빠른 분석 가능
- **활용 예시:**
 - 매출/주문 데이터 실시간 반영
 - 실시간 센서 데이터 적재
 - 정기적 보고용 데이터 자동 적재
- **응용 가능:**
 - SQL 기반 CDC 연계
 - Power BI 실시간 대시보드와 연동