



핵심 데이터 개념

데이터 형식 식별하기

데이터 개념

- 데이터: 정보를 기록하는 팩트(숫자, 설명, 관측값 등)의 모음
- 엔터티: 조직에서 중요하게 다루는 객체 (예: 고객, 제품, 주문)
- 속성: 엔터티의 특징 (예: 고객의 이름, 주소, 전화번호)

데이터 유형

- 정형 데이터
 - 특징: 고정된 스키마 준수, 테이블(행/열) 형태
 - 예시: 고객 테이블, 제품 테이블
 - 저장 방식: 관계형 데이터베이스 (SQL 기반)
- 반정형 데이터 (Semi-structured Data)
 - 특징: 일부 구조 존재, 엔터티 간 속성 차이 허용
 - 대표 형식: JSON, XML
 - 예시: 고객 1은 이메일 여러 개, 고객 2는 이메일 없음
- 비정형 데이터 (Unstructured Data)
 - 특징: 특정 구조 없음
 - 예시: 문서(Word, PDF), 이미지, 오디오, 비디오, 로그 파일

데이터 저장소

- 파일 저장소: 문서, 이미지, 기타 파일 저장
- 데이터베이스: 정형, 반정형 데이터를 중심으로 엔터티와 이벤트 기록

파일 스토리지

파일 저장소

- 모든 컴퓨팅 시스템의 핵심 요소
- 로컬 저장(하드디스크), 이동식 저장(USB), 중앙 공유 스토리지(클라우드)

- 클라우드: 비용 효율적, 안전, 안정적

파일 형식 선택 요인

- 저장하려는 데이터의 유형(정형, 반정형, 비정형)
- 데이터를 읽고/쓰고/처리해야 하는 애플리케이션과 서비스
- 사람이 읽을 수 있어야 하는지, 또는 효율적 저장·처리를 중시할지 여부

주요 파일 형식

1. 구분된 텍스트 파일

- CSV, TSV, 공백 구분, 고정 너비 데이터
- 사람이 읽을 수 있음, 정형 데이터 저장에 적합

2. JSON (JavaScript Object Notation)

- 계층 구조 문서 스키마
- 정형·반정형 데이터 모두 표현 가능

3. XML (Extensible Markup Language)

- 태그 기반 데이터 표현
- 과거 널리 쓰였으나 현재는 JSON으로 대체되는 추세

4. BLOB (Binary Large Object)

- 원시 이진 데이터 저장
- 이미지, 비디오, 오디오, 애플리케이션 문서 등 비정형 데이터에 활용

5. 최적화된 파일 형식

- 저장 공간·처리 속도 최적화, 압축·인덱싱 지원
- **Avro**: 행 기반, JSON 헤더 + 이진 데이터
- **ORC**: 열 기반, Hive 최적화
- **Parquet**: 열 기반, 중첩 데이터 효율적 저장·처리

데이터베이스 검색

데이터베이스

- 데이터를 저장하고 쿼리할 수 있는 중앙 시스템
- 단순한 파일 시스템도 데이터베이스의 일종이지만, 전문적 맥락의 데이터베이스는 데이터 레코드를 관리하는 전용 시스템을 의미

관계형 데이터베이스

- 정형 데이터를 저장하고 쿼리하는 데 널리 사용
- 데이터는 엔터티(고객, 제품, 판매 주문 등)를 나타내는 테이블에 저장
- 기본 키(Primary Key): 엔터티 인스턴스를 고유하게 식별
- 참조 키(Foreign Key): 다른 테이블의 엔터티를 참조
- 정규화(Normalization): 중복 데이터 제거, 효율적 저장
- SQL (Structured Query Language): 테이블 관리 및 쿼리 언어
 - ANSI 표준 기반으로 다양한 데이터베이스 시스템에서 공통적으로 사용됨

비관계형 데이터베이스

- 데이터에 관계형 스키마를 적용하지 않는 관리 시스템
- **NoSQL** 데이터베이스라고도 불림. 일부는 SQL 변형 언어를 지원하기도 함

1. 키-값 데이터베이스

- 각 레코드 = 고유한 키 + 값
- 값은 모든 형식 가능

Products	
Key	Value
123	"Hammer (\$2.99)"
162	"Screwdriver (\$3.49)"
201	"Wrench (\$4.25)"

2. 문서 데이터베이스

- 키-값 DB의 확장
- 값이 JSON 문서이며, 구문 분석 및 쿼리에 최적화됨

Customers	
Key	Document
1	{ "name": "Joe Jones", "email": "joe@litware.com" }
2	{ "name": "Samir Nadoy", "email": "Samir@northwind.com" }


3. 열 패밀리 데이터베이스

- 행과 열로 구성된 테이블 형식
- 열을 열 패밀리(Column Family)라는 그룹으로 나누어 저장
- 관련된 열 집합을 보유

Orders				
Key	Customer		Product	
	Name	Address	Name	Price
1000	Joe Jones	1 Main St.	Hammer	2.99
1001	Samir Nadoy	123 Elm Pl.	Wrench	4.25

4. 그래프 데이터베이스

- **노드(Node)** = 엔터티, **관계(Relationship)** = 노드 간 연결
- 엔터티 간 관계 중심 데이터 모델에 적합



트랜잭션 데이터 처리

트랜잭션 데이터 처리 시스템

- 비즈니스 컴퓨팅의 기본 기능
- 특정 이벤트(예: 금융 거래, 소매 결제)를 캡슐화한 **트랜잭션**을 기록
- 트랜잭션 = 소규모의 개별 작업 단위. 즉, DB의 상태를 변경시키기 위해 수행하는 작업 단위
- 하루 수백만 건의 대규모 트랜잭션 처리 가능
- 데이터에 신속하게 액세스해야 함
- 이러한 처리 작업을 **OLTP** (Online Transaction Processing)라 부름

OLTP 시스템

- **CRUD 작업**(생성 Create, 검색 Read, 업데이트 Update, 삭제 Delete)을 지원
- 읽기와 쓰기에 최적화된 데이터베이스 시스템 사용
- 데이터 **무결성**을 보장하기 위해 **트랜잭션 방식** 적용
- **ACID 의미 체계**를 지원
- 비즈니스 데이터를 처리하는 라이브 애플리케이션 (LOB: Line of Business 애플리케이션)을 지원

ACID 특성

- **원자성(Atomicity)**
 - 트랜잭션은 전부 성공하거나 전부 실패해야 함
 - 예: 계좌 이체 시, 인출과 입금 둘 다 완료되지 않으면 전체 트랜잭션 실패
- **일관성(Consistency)**
 - 데이터는 항상 유효한 상태에서 유효한 상태로만 변환됨
 - 예: 인출 후 입금이 반영된 상태여야 함
- **격리성(Isolation)**
 - 동시 실행되는 트랜잭션은 서로 간섭 불가
 - 예: 계좌 이체 중에 잔액 조회 시, 이전·이후 상태가 섞이지 않아야 함
- **내구성(Durability)**
 - 커밋된 트랜잭션은 영구적으로 유지됨
 - 예: 전원이 꺼져도 계좌 잔액 변경이 보존되어야 함

분석 데이터 처리 살펴보기

분석 데이터 처리 시스템

- 읽기 전용(대부분 읽기) 시스템
- 방대한 양의 기록 데이터 또는 비즈니스 메트릭 저장
- 특정 시점의 데이터 스냅샷 또는 일련의 스냅샷 기반 분석

분석 아키텍처 공통 요소

1. 운영 데이터 → 데이터 레이크로 **추출·변환·로드(ETL)**
2. 데이터 레이크에 파일 기반 데이터 저장 → **테이블 스키마**로 로드
 - SQL 엔진 기반 데이터 웨어하우스
 - Spark 기반 데이터 레이크하우스
3. 데이터 웨어하우스 → **OLAP 모델(큐브)**로 집계 가능
 - **팩트 테이블**: 수치(측정값)
 - **차원 테이블**: 날짜, 고객, 제품 등
 - 예: 날짜·고객·제품별 판매 수익 집계
4. 데이터 레이크·웨어하우스·OLAP 모델을 쿼리 → **보고서, 시각화, 대시보드** 생성

데이터 저장소와 모델

- **데이터 레이크**
 - 대량의 파일 기반 데이터 저장
 - 대규모 분석 처리의 공통 요소
- **데이터 웨어하우스**
 - 읽기 작업 최적화.
 - 관계형 스키마 기반, 보고·시각화 지원
 - OLTP 데이터 원본의 데이터를 **비정규화**하여 로드할 수 있음
- **데이터 레이크하우스**
 - 데이터 레이크의 유연성 + 웨어하우스의 관계형 쿼리 의미 체계 결합
- **OLAP 모델**
 - 분석 워크로드에 최적화된 집계 데이터 저장
 - 여러 수준·차원에서 집계 가능 → **드릴업/드릴다운** 분석 지원
 - 미리 집계된 데이터 → 쿼리 속도가 빠름

사용자별 활용

- **데이터 과학자**: 데이터 레이크의 파일 기반 데이터로 모델링·탐색

- **데이터 분석가:** 데이터 웨어하우스 테이블 쿼리 → 복합 보고서·시각화 생성
- **비즈니스 사용자:** OLAP 모델 기반 보고서·대시보드 소비