



대규모 분석

데이터 웨어하우징 아키텍처

데이터 수집 및 처리

- 원본: 트랜잭션 DB, 파일, 실시간 스트림 등
- 방식: **ETL(Extract → Transform → Load)** 또는 **ELT(Extract → Load → Transform)**
 - ETL: 변환 후 저장소에 로드
 - ELT: 저장소에 로드 후 변환
- 특징:
 - 정적 데이터 → 일괄 처리(batch)
 - 실시간 데이터 → 스트리밍 처리
 - 분산 클러스터 사용 → 대규모 병렬 처리

분석 데이터 저장소

- 데이터 웨어하우스 (RDB 기반)
- 데이터 레이크 (파일 기반, 원천 데이터 저장)
- 데이터 레이크하우스 (하이브리드): 웨어하우스 + 레이크 기능 결합

분석 데이터 모델

- 목적: 분석/시각화를 쉽게 하기 위해 데이터 미리 집계
- 형태: 큐브(Cube)
 - 다차원 집계 (예: 제품 × 지역별 매출)
 - “드릴업/드릴다운” 분석 가능
- 데이터 값과 차원 간 관계 캡슐화

데이터 시각화

- 보고서, 대시보드, 대화형 시각화
- 활용:
 - 비즈니스 추세, 비교, KPI 확인
 - 문서, PPT, 웹 대시보드, 인쇄 보고서 등 다양한 형식

- 셀프서비스 분석 지원 → 비전문가도 활용 가능
-

데이터 수집 파이프라인

- 대규모 분석 저장소로 데이터를 옮기기 위해 ETL 파이프라인을 구성해 오케스트레이션
- 일괄 처리와 스트리밍 모두 지원하며 분산 처리로 대량 데이터 병렬 처리 가능

구현 옵션

- Azure Data Factory를 사용해 파이프라인 생성과 실행
- Microsoft Fabric 통합 작업 영역의 파이프라인 기능으로 전체 구성요소를 한곳에서 관리

파이프라인 구성 요소

- 파이프라인 : 데이터 작업을 묶는 상위 워크플로 단위
- 활동 : 데이터를 읽고 변환하고 쓰는 개별 작업 단위
- 데이터 세트 : 입력 원본과 출력 결과를 나타내는 논리 객체
- 데이터 흐름 : 활동들이 데이터를 단계적으로 조작하는 흐름 정의
- 연결된 서비스 : 각 단계에서 사용할 외부 서비스와의 연결 정보

동작 방식 예시

- 입력을 Azure Blob Storage에서 수집
- Azure SQL Database 저장 프로시저로 관련 값 조회
- Azure Functions로 사용자 지정 로직 적용
- Azure Databricks에서 본격 처리 실행
- 결과를 Microsoft Fabric 같은 대상 저장소로 적재

핵심 포인트

- ETL 또는 ELT 패턴으로 설계해 분석 쿼리에 최적화된 구조 생성
 - 연결된 서비스를 통해 단계별로 가장 적합한 기술을 선택해 사용
 - 증분 처리와 자동화로 반복 가능한 안정적 데이터 파이프라인 구현
-

분석 데이터 저장소

데이터 웨어하우스 (Data Warehouse)

- 정의: 데이터 분석에 최적화된 관계형 데이터베이스
- 특징

- 트랜잭션 데이터 → 집계 중심 스키마 변환
- 팩트 테이블: 수치 데이터 저장 (예: 판매 주문)
- 차원 테이블: 분석 기준 제공 (예: 고객, 제품, 매장, 시간)
- 스키마 유형
 - 별모양 스키마 (Star Schema): 중앙 팩트 + 다수 차원
 - 눈송이 스키마 (Snowflake Schema): 차원 계층 구조 확장
- 적합한 경우: 구조화된 데이터, SQL 기반 쿼리

데이터 레이크 (Data Lake)

- 정의: 분산 파일 시스템 기반 대규모 파일 저장소
- 특징
 - 구조화 / 반구조화 / 비정형 데이터 저장 가능
 - 스키마-온-리드 방식: 저장 시 제약 없음, 읽을 때 스키마 적용
 - Spark / Hadoop을 통해 대규모 쿼리 및 분석 처리
- 적합한 경우: 다양한 형태의 데이터 수집 및 유연한 분석

하이브리드 접근 (데이터 레이크하우스, Lakehouse)

- 정의: 데이터 웨어하우스 + 데이터 레이크 기능 결합
- 특징
 - 원시 데이터는 레이크에 저장
 - SQL 분석 엔드포인트로 테이블처럼 조회 가능
 - Delta Lake 기반 → 스키마 강제, 트랜잭션 일관성 지원
 - 배치/스트리밍 처리 + SQL API 제공
- 적합한 경우: Spark 유연성과 관계형 DB 안정성을 동시에 필요로 할 때

분석 저장소용 Azure 서비스

1. Microsoft Fabric

- 엔드투엔드 데이터 분석 솔루션
- 데이터 레이크 + Spark + SQL 웨어하우스 통합
- 기본 제공: 실시간 분석, 데이터 파이프라인, 권한 관리
- 적합: 단일 통합 분석 환경을 원할 때

2. Azure Databricks

- Apache Spark 기반 데이터 분석 플랫폼

- 데이터 과학, 머신러닝, 대화형 Notebook 최적화
- SQL 기능 내장, 다중 클라우드 지원
- 적합: Spark 전문성 활용, 멀티 클라우드 운영 필요할 때

활용 시나리오 예시

- 데이터 → 데이터 레이크 적재 (ELT 방식)
- Azure Databricks Notebook으로 대규모 처리
- 처리 결과 → Microsoft Fabric Warehouse 테이블에 로드
- 최종적으로 SQL 기반 BI 툴에서 쿼리 및 시각화