



실시간 분석

배치 처리 및 스트림 처리 이해

배치 처리 (Batch Processing)

- **방식:** 일정량의 데이터를 모아서 한 번에 처리
- **예시:**
 - 신용카드 회사 → 월별 청구서 발행
 - 교통량 → 일정 시간마다 모아 일괄 집계
- **장점:**
 - 대량 데이터 효율적 처리
 - 시스템 사용량이 적을 때(야간 등) 예약 실행 가능
- **단점:**
 - 결과 확인까지 지연 발생
 - 작은 데이터 오류 → 전체 배치 실패 가능

스트림 처리 (Stream Processing)

- **방식:** 데이터가 들어오는 즉시 실시간 처리
- **예시:**
 - 주식 거래 → 가격 변동 시 즉각 반응
 - 게임 → 실시간 보상 제공
 - IoT 센서 → 화재 감지 시 즉시 경보
- **장점:**
 - 실시간 응답 가능
 - 이벤트 단위로 즉각 분석
- **단점:**
 - 복잡한 분석보다는 단순 집계/반응에 주로 사용

결합 (Lambda / Delta 아키텍처)

- 대부분의 대규모 분석 솔루션은 두 방식을 혼합

- 스트림 처리: 실시간 캡처 및 알림, 대시보드 표시
 - 배치 처리: 주기적 집계 및 심층 분석, 데이터 웨어하우스 적재
 - 대표 아키텍처: Lambda, Delta Architecture
-

스트림 처리 아키텍처의 공통 요소

스트림 처리를 위한 일반 아키텍처

1. 이벤트 생성 (Event Source)
 - 데이터 발생 지점
 - 예시: IoT 센서 신호, 소셜 미디어 메시지, 로그 파일, 거래 이벤트
2. 스트리밍 소스 (Queue / Broker)
 - 이벤트 데이터를 캡처하고 순서 보장, 중복 방지
 - 단순: 데이터베이스 테이블, 스토리지 폴더
 - 고급: Event Hub, Kafka 같은 큐 기반 수집기
3. 스트림 처리 (Stream Processing / Permanent Queries)
 - 이벤트 유형별 필터링
 - 계산/추출 (파생 변수 생성)
 - 시간 기반 집계 (윈도우: 분당 이벤트 수, 평균 값 등)
4. 출력 (Sink / Destination)
 - 결과 저장소 또는 실시간 시각화
 - 예시:
 - 파일 저장 (Data Lake, Blob)
 - 테이블 저장 (SQL DB, Fabric, Databricks)
 - 대시보드 (Power BI)
 - 다시 큐에 넣어 추가 처리

Azure에서 사용되는 스트림 처리 기술

- 실시간 분석 서비스
 - Azure Stream Analytics: PaaS, SQL 유사 쿼리로 스트리밍 처리 정의
 - Spark Structured Streaming: Databricks/Fabric 기반, 복잡한 처리 가능
 - Microsoft Fabric Real-Time Analytics: 원스톱 실시간 분석 플랫폼
- 스트림 소스

- Azure Event Hubs: 대규모 이벤트 큐 관리 (순서 보장, 한 번만 처리)
- Azure IoT Hub: IoT 디바이스 이벤트 최적화
- Data Lake Gen2: 스트리밍 데이터 원본도 가능
- Apache Kafka: 오픈소스 큐 시스템, Spark와 자주 연동
- 스트림 싱크(출력)
 - Event Hubs: 추가 처리 파이프라인 연결
 - Data Lake, OneLake, Blob Storage: 파일 저장
 - SQL DB, Fabric, Databricks: 구조적 분석용 저장
 - Power BI: 실시간 대시보드/시각화

Microsoft Fabric 실시간 인텔리전스

역할

- 엔드 투 엔드 스트리밍 솔루션
이벤트 기반, 로그, 스트리밍 데이터를 통합하여 실시간으로 분석·시각화
- 확장성
GB부터 PB 규모까지 처리 가능
- 코드 없는 커넥터
다양한 원본(내부/외부) 데이터를 쉽게 연결 → 시각적 인사이트, 지리 공간 분석, 트리거 기반 액션

주요 구성 요소

- 실시간 허브 (Real-Time Hub)
 - 조직의 중앙 카탈로그
 - 데이터 액세스·추가·탐색·공유 간소화
 - 데이터 가용성·접근성 보장 → 빠른 의사 결정 가능
 - 여러 원본 스트림 데이터를 통합하여 전사적 BI 실현
- 실시간 데이터 탐색 (Exploration)
 - 데이터 패턴, 이상 탐지, 예측 수량을 시각화 도구 + Copilot + 자연어 질의로 탐색 가능
 - 모든 사용자가 쉽게 데이터 이해 가능
- 실시간 대시보드 + Reflex 경고
 - 실시간 시각화 지원 (Power BI 유사 경험)
 - 조건 만족 시 자동 알림/액션 실행 → 인사이트 → 즉각적인 대응

Apache Spark 구조적 스트리밍

1. Spark

- 분산 처리 프레임워크 → 대규모 데이터(GB ~ PB)를 여러 클러스터 노드에서 병렬 처리
- 지원 언어: Python, Scala, Java
- 사용 방식: 일괄 처리(batch) + 스트리밍 처리(streaming)

2. Spark 구조적 스트리밍 (Structured Streaming)

- Spark의 DataFrame API 기반 스트리밍 처리
- 스트림 원본: Kafka, 파일 저장소, 네트워크 포트 등
- 스트림은 "무한 데이터 프레임(unbounded DataFrame)" 으로 표현됨
- 쿼리 정의: 선택(select), 산출(transform), 집계(aggregate) → 결과를 또 다른 DataFrame으로 저장/분석
- 실시간 분석: Spark 기반 데이터 레이크나 분석 스토리지에 적합

3. Delta Lake

- 오픈 소스 스토리지 계층
- 기능:
 - 트랜잭션 일관성 (ACID 보장)
 - 스키마 적용 (Schema Enforcement)
 - Batch + Streaming 통합
- 스트리밍 활용:
 - Delta Lake 테이블을 스트리밍 소스 또는 싱크로 사용 가능
- Spark Structured Streaming과 결합 → 데이터 레이크를 관계형 테이블처럼 SQL 기반 쿼리 가능

4. Microsoft Fabric & Databricks에서 활용

- 두 플랫폼 모두 Spark + Delta Lake 지원 내장
- 따라서 실시간 스트리밍 + 일괄 처리 + 관계형 분석을 한 번에 구현 가능